Системное программирование

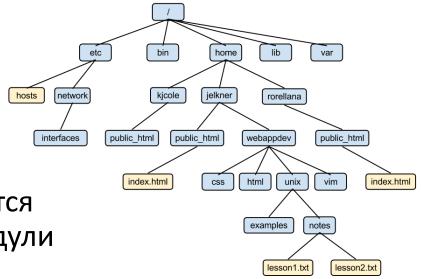
Тема 2

Файлы в UNIX

Файлы

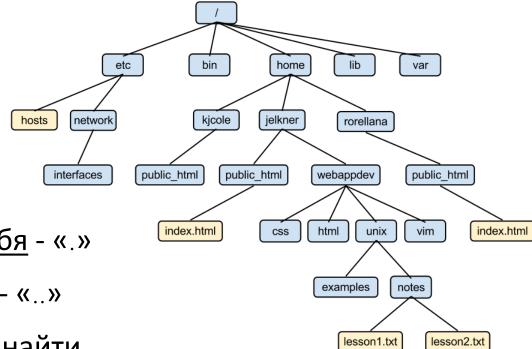
Файл – именованный набор данных.

 В UNIX «все есть файл» - в виде файлов представляются устройства, запущенные программы и некоторые модули ядра.



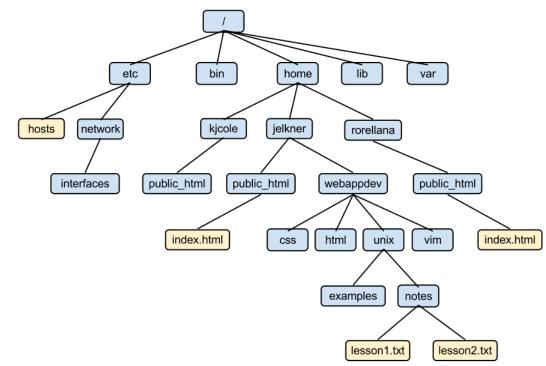
Файловая система UNIX

- Структура файловой системы дерево.
- Корень дерева каталог с именем «/».
- Из корневого каталога есть путь до любого файла/каталога (абсолютный путь).
- Любой каталог содержит <u>ссылку на самого себя</u> «.»
- Любой каталог содержит <u>ссылку на родителя</u> «..»
- Из-за наличия «..» из любого каталога можно найти путь до любого файла (результирующее имя не должно превышать РАТН_МАХ).



Основные каталоги

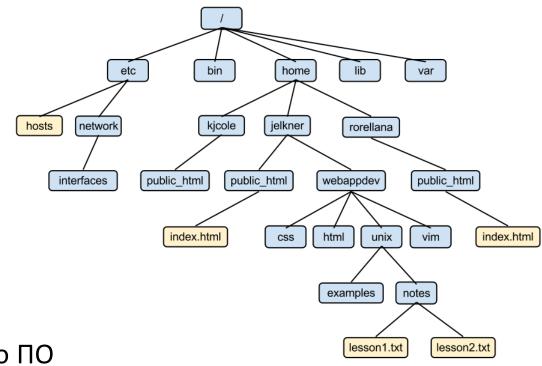
```
/bin – основные исполняемые файлы
/sbin – системные исполняемые файлы
/lib – основные библиотеки
/boot – загрузочные файлы
/dev – файлы устройств
/home – домашние каталогов пользователей
/root – каталог суперпользователя root
/tmp – временные файлы
/run – системные временные файлы
/media, /run/media – точки монтирования съемных носителей
/mnt – иные точки монтирования
/sys — информация о системе
/proc – информация о процессах
```



См. стандарт FHS

Основные каталоги

```
/usr — каталог установки системного ПО
  /usr/(bin, lib, sbin) – аналогично /(bin, lib, sbin)
  /usr/share – неизменяемые данные приложений
  /usr/include – заголовочные файлы библиотек
  /usr/local/* - каталог локальной установки ПО
    /usr/local/etc – файлы конфигурации локального ПО
/opt – каталог установки дополнительного ПО
/var – данные приложений
  /var/log – логи
  /var/opt – данные дополнительного ПО
/etc – конфигурационные файлы
  /etc/opt – конфигурационные файлы дополнительного ПО
```



Права доступа к файлу

- Каждый файл имеет пользователя-владельца и группу-владельца.
- Существует 3 основных типа прав доступа к файлу право на чтение (r), право на запись (w) и право на выполнение (x, запуск программы из файла).

Примечание: для каталогов право на выполнение (**x**) означает право на доступ к элементам каталога.

- Существует 3 группы прав доступа— права владельца файла, права членов группы-владельца файла, права всех остальных пользователей.
- Права кодируются либо в виде последовательности букв (rwxrwxrwx), либо в виде восьмеричного числа (777)

```
$ Ls -L
```

-<mark>rwxr-xr-x</mark> 5 user group 4096 Sep 7 19:31 файл

Диск

• • •

inode #6310

inode #6311

inode #6312

..

inode

Всякий файл имеет <u>единственный</u> ассоциированный с ним **индексный узел** (inode).

В inode хранятся основные свойства файла:

- число жестких ссылок (поле nlink);
- размер файла (поле size);
- флаги доступа (поле mode);
- владелец файла и группа-владелец;
- время последнего доступа и изменения
- ссылка на список блоков с данными и др.



data block 100 data block 101 data block 102 data block 103

Каталоги

Каталог — файл специального вида, хранящий ссылки на другие (вложенные) файлы.

- На диске каталоги хранят пары <имя файла, номер inode файла>.
- Каталоги служат для сопоставления имени файла с данными.
- Сопоставление имени начинается либо с корневого каталога «/», которому соответствует inode с номером 2, либо с рабочего каталога, ассоциированного с процессом и inode которого также известен.

Каталоги

/dir1/foo.txt /bar.txt

/dir2/tmp

inode #1001
size
mode
owner
nlink=1
blocks

inode #1002
size
mode
owner
nlink=1
blocks

Данные dii	1 на диске
	1001
	2
foo.txt	6311
bar.txt	6312

Данные dii	2 на диске
	1002
	2
tmp	6312

1	inode #6311
	size
	mode
	owner
	nlink=1
	blocks

X	inode #6312
	size
	mode
	owner
	nlink=2
	blocks

Жесткие ссылки

Жесткая ссылка — запись в каталоге.

- На один и тот же inode могут ссылаться несколько записей в каталогах => на один и тот же файл может быть несколько жестких ссылок.
- Все жесткие ссылки на файл равноправны.
- Множественные жесткие ссылки на каталоги запрещены (риск бесконечных циклов в файловой системе).
- Данные файла удаляются с диска только тогда, когда исчезает последняя жесткая ссылка на файл.

Символические ссылки

Символическая ссылка — специальный файл, хранящий путь к связанному файлу и позволяющий взаимодействовать с ним прозрачно для пользователя.

- В отличие от жесткой ссылки, символическая ссылка самостоятельный файл.
- Символические ссылки не ограничивают удаление файла => они могут быть "висячими" указывать на несуществующий файл.

Файлы устройств

Некоторые устройства в UNIX представляются в виде файлов устройств (каталог /dev).

- Устройства делятся на <u>блочные</u> (буферизованы, случайный доступ) и <u>символьные</u> (небуферизованы, обычно последовательный доступ).
- Чтение/запись файла устройства соответствуют чтению/записи с устройства напрямую.

Примеры: /dev/sd* - жесткие диски/SSD, /dev/nvme* - NVME-SSD, /dev/mem – физическая ОЗУ

Псевдоустройства

Некоторые файлы, похожие на файлы устройств, на самом деле не связаны ни с одним физическим устройством. Такие файлы называются файлами псевдоустройсв. Примеры:

- /dev/random генератор случайных чисел;
- /dev/urandom генератор псевдослучайных чисел;
- /dev/zero **бесконечное устройство, заполненное 0**;
- /dev/full "всегда полное" устройство, в которое нельзя ничего записать;
- /dev/null "всегда пустое" устройство, из которого нельзя ничего прочитать;
- /dev/tty псевдотерминал процесса.

Специальные файлы

Помимо обычных файлов, каталогов и файлов устройств есть ряд других объектов, которые могут представляться как файлы.

- каналы (FIFO, см. *mkfifo*)
- очереди сообщений
- сокеты
- файлы разделяемой памяти

Вызов open

Для того, чтобы работать с файлом внутри программы, его необходимо сначала открыть вызовом **open**.

```
int fd = open(const char *pathname, int flags, mode_t mode);
```

Параметры:

```
pathname - путь к файлу, flags - режим доступа к файлу и дополнительные флаги, mode - флаги прав доступа к создаваемому файлу.
```

Вызов open вызвращает -1 в случае ошибки. В случае успешного выполнения возвращается **дескриптор файла**.

Флаги open

Комбинация следующих флагов может быть передана в параметре flags.

- O_RDONLY, O_WRONLY, O_RDWR открыть файл на чтение/на запись/на чтение-запись (указать можно только один из флагов).
- O_CREAT создать файл, если он не существует;
- O_EXCL вернуть ошибку, если указан O_CREAT, но файл уже есть;
- O_TRUNC если файл существует, то стереть весь его контент;
- O_APPEND всегда производить запись в конец файла.
- O_NOFOLLOW если файл является символической ссылкой, открыть сам файл ссылки.
- O_SYNC немедленно записывать все изменения в файле на диск.

Константы доступа

Если указан флаг O_CREAT, то в параметре должны передаваться права доступа к создаваемому файлу. Права задаются комбинацией следующих констант.

Права	Владельца	Группы	Остальных
На чтение	S_IRUSR	S_IRGRP	S_IROTH
На запись	S_IWUSR	S_IWGRP	S_IWOTH
На выполнение	S_IXUSR	S_IXGRP	S_IXOTH
Bce	S_IRWXU	S_IRWXG	S_IRWXO

S_IRWXU | S_IRGRP — какой набор прав?

Вызов close

После завершения работы с *дескриптором* его необходимо закрыть вызовом close.

```
int close(int fd);
```

Сам файл будет окончательно закрыт тогда, когда будут закрыты все связанные с ним дескрипторы.

Все дескрипторы автоматически закрываются, когда завершается программа.

Таблицы дескрипторов и открытых файлов

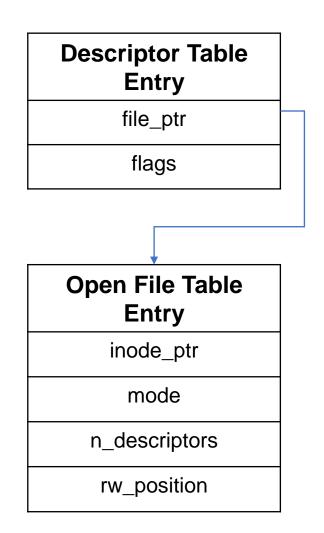
Для каждого процесса в пространстве ядра создается **таблица дескрипторов. Дескриптор**, возвращаемый вызовом open — это индекс в таблице дескрипторов процесса.

Для каждого открытого файла существует запись в общесистемной таблице открытых файлов.

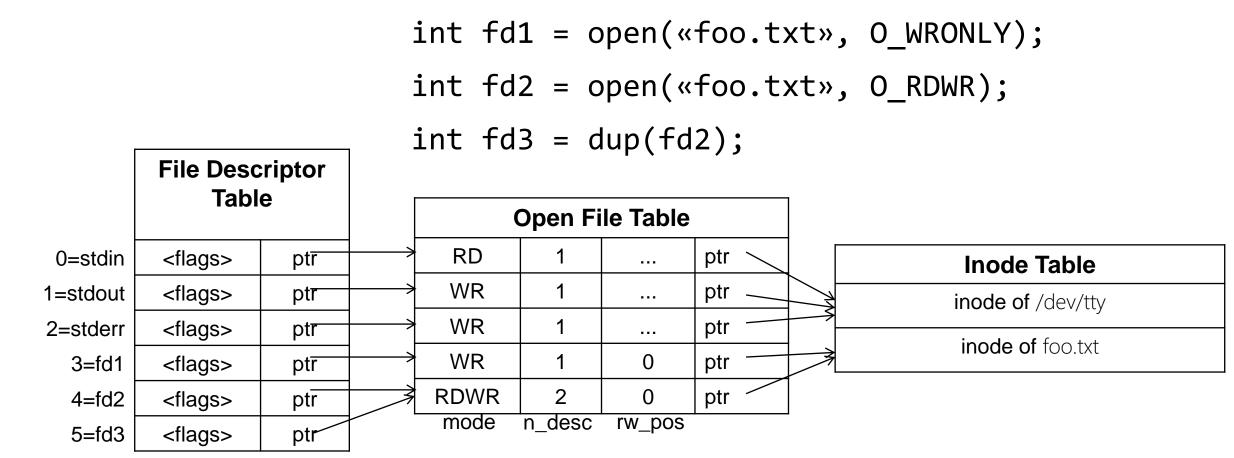
Записи в таблице дескрипторов указывают на записи в таблице открытых файлов.

Вызов **open()** создает новую запись в таблице открытых файлов и соответствующую ей запись в таблице дескрипторов.

Вызов **close()** закрывает запись в таблице дескрипторов. Запись в таблице открытых файлов закрывается только когда не останется связанных с ней дескрипторов.



Таблицы дескрипторов и открытых файлов



Маска прав доступа. Вызов umask

В некоторых случаях нежелательно, чтобы программа создавала файлы с определенными разрешениями.

Разрешения, которые не нужно устанавливать при создании файла, задаются маской прав доступа.

Маска прав доступа по умолчанию имеет значение 022 (соответствует ----wx-wx).

Изменяется маска прав вызовом umask() и утилитой umask.

```
mode_t umask(mode_t mask);
```

Вызов возвращает предыдущую маску прав или -1 в случае ошибки.

```
//с какими правами доступа создастся file?
umask(S_IWOTH|S_IXUSR);
int fd = open("file", O_RDWR|O_CREAT, S_IRWXU|S_IRWXO);
```

Вызовы read и write (примеры 1, 2)

Чтение и запись в файл производятся вызовами read и write.

```
ssize_t read(int fd, void* buf, size_t count);
ssize_t write(int fd, const void* buf, size_t count);
```

Параметры:

```
fd — дескриптор открытого файла,
buf — данные для записи либо буфер для чтения данных,
count — размер данных, которые требуется прочитать/записать.
```

Вызовы возвращают число фактически прочитанных/записанных байт (0 означает конец файла, -1 означает ошибку).

Позиция чтения/записи. Вызов Iseek (примеры 2,3)

С каждым открытым файлом ассоциирована позиция чтения/записи — позиция в файле, с которой начнется следующая операция.

Позиция автоматически изменяется вызовами read/write. Изменить позицию можно вызовом lseek:

```
off_t lseek(int fd, off_t offset, int whence);

Параметры:

fd — дескриптор файла,
 offset — величина смещения позиции,
 whence - одно из значений SEEK SET, SEEK CUR, SEEK END
```

Open File Table Entry
inode_ptr
mode
n_descriptors
rw_position

Позиция чтения/записи. Вызов Iseek

```
int fd = open("foo.txt", O_RDWR);
off t off1 = lseek(fd, 3, SEEK SET);
off t off2 = lseek(fd, 5, SEEK CUR);
off t off3 = lseek(fd, -3, SEEK END)
```

Дырки в файлах

Дырка в файле – область файла, физически отсутствующая на диске.

Чтение в пределах дырки возвращает набор 0, запись – заполняет дырку.

Вызов ftruncate

Для изменения размера файла можно использовать вызов ftruncate

```
int ftruncate(int fd, off_t length);
```

Вызов возвращает 0 в случае успеха и -1 в случае ошибки.

Если размер файла увеличивается в большую сторону, в конце файла образуется дырка.

Свойства файла. Вызов fstat (пример 3)

Для получения информации о файле используется вызов stat/fstat.

```
int stat(const char *pathname, struct stat *statbuf);
int fstat(int fd, struct stat *statbuf);
```

Вызов возвращает 0 в случае успеха и -1 в случае ошибки.

Вызов заполняет структуру, адрес которой передается в statbuf.

Свойства файла. Вызов fstat

```
struct stat {
            st_dev; /* ID устройства хранения */
   dev t
   ino t
            st ino; /* Hoмep inode файла */
   mode t st mode; /* Тип файла и флаги доступа */
   nlink t st nlink; /* Количество жестких ссылок */
   uid t
            st uid; /* ID пользователя-владельца */
   gid t
            st gid; /* ID группы-владельца */
   off t
            st size; /* Pasmep */
   off t
            st blksize; /* Размер в блоках по 512 байт*/
   time t
            st atime; /* Время последнего доступа */
   time_t st_mtime; /* Время последнего изменения */
            st ctime; /* Время последнего изменения inode */
   time t
```

Свойства файла. Вызов fstat

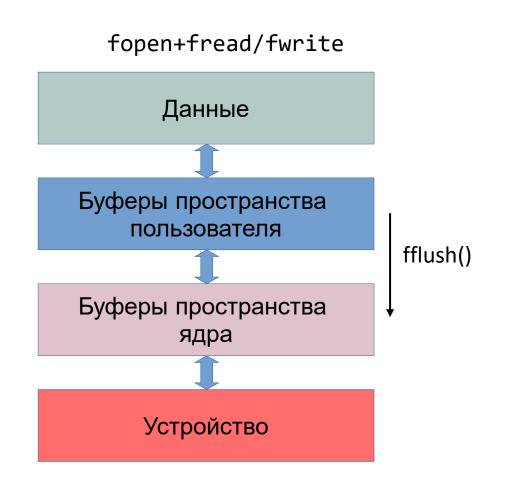
Для проверки типа файла используется ряд функций-макросов:

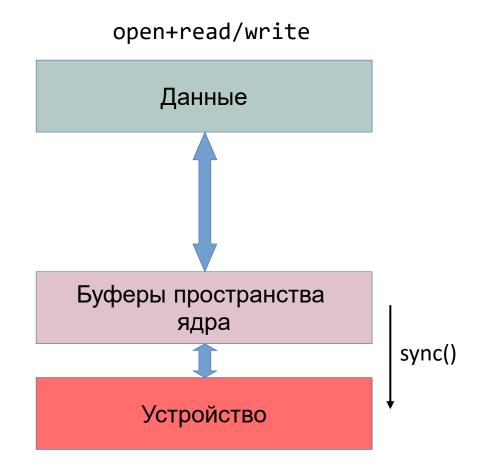
```
S_ISREG(st_mode) — обычный файл;
S_ISDIR(st_mode) — каталог;
S_ISCHR(st_mode) — файл символьного устройства;
S_ISBLK(st_mode) — файл блочного устройства;
S_ISLNK(st_mode) — символическая ссылка.
S_ISFIFO(st_mode) — канал.
```

Для извлечения только флагов доступа используется выражение st_mode & 0777

```
struct stat s;
stat("foo.txt", &s); //аналогично open+fstat+close
printf(«Is dir? %d", S_ISDIR(s.st_mode));
printf(«Acess mode %o", (s.st_mode & 0777));
```

Буферизация ввода-вывода (пример 4)





Переименование файлов. Вызов rename

Файл может быть переименован вызовом rename. С помощью этого же вызова файл может быть перемещен в другой каталог.

```
int rename(const char *oldpath, const char *newpath);
```

Вызов возвращает 0 в случае успеха, -1 в случае ошибки.

При перемещении в пределах одной файловой системы (например, в пределах одного раздела диска), rename не производит копирования данных.

Перемещение уже открытого файла не сказывается на работе с ним.

Удаление файлов. Вызов unlink

Файл (но не каталог) может быть удален вызовом unlink.

```
int unlink(const char *pathname);
```

Вызов возвращает 0 в случае успеха, -1 в случае ошибки.

Файл не будет удален с диска, пока на него есть жесткие ссылки или пока он открыт в программе.

Ссылки. Вызовы link и symlink

Жесткая ссылка на файл создается вызовом link.

```
int link(const char *target, const char *linkpath);
```

Символическая (мягкая) ссылка создается вызовом symlink.

```
int symlink(const char *target, const char *linkpath);
```

Вызовы возвращают 0 в случае успеха, -1 в случае ошибки.

В случае link путь в target обязан существовать, в случае symlink — не обязан.

Создание каталогов. Вызов mkdir

Для создания каталога используется вызов mkdir.

```
int mkdir(const char* path, mode_t mode);
```

Вызов возвращает 0 в случае успеха, -1 в случае ошибки.

Bce родительские каталоги в пути path должны существовать.

Параметр mode указывает флаги доступа к создаваемому каталогу (S_IRXU, S_IRWXG, ...).

Удаление каталогов. Вызов rmdir

Для удаления каталога используется вызов rmdir.

```
int rmdir(const char* path);
```

Вызов возвращает 0 в случае успеха, -1 в случае ошибки.

Каталог должен быть пустым.

Рабочий каталог. Вызов chdir

У каждой выполняющейся программы указан рабочий каталог — каталог, от которого отсчитываются относительные пути.

Относительный путь — путь, не начинающийся с корня файловой системы (с /).

Узнать рабочий каталог можно вызовом getcwd, изменить — вызовом chdir:

```
char* getcwd(char* buf, size_t size);
int chdir(const char *path);
```

Вызов chdir возвращает -1 в случае ошибки и 0 — в случае успеха. Вызов getcwd возвращает buf в случае успеха и NULL в случае ошибки.

Просмотр каталогов. Функция scandir

Для чтения информации о содержимом каталога используется функция scandir (см. след слайд).

Функция возвращает количество количество полученных элементов каталога или -1 в случае ошибки.

Стоит посмотреть: функции opendir, readdir, telldir, seekdir, rewinddir

Просмотр каталогов. Функция scandir

```
namelist — адрес, по которому будет записан результат, filter — функция, фильтрующая элементы каталога (можно передать NULL), compar — функция, сортирующая элементы каталога.
```

В качестве параметра compar можно передать функцию alphasort. Массив, возвращаемый в namelist, нужно удалить после использования.

Права доступа к файлу. Вызов chmod

Изменение флагов доступа к существующему файлу осуществляется вызовом chmod.

```
int chmod(const char *pathname, mode_t mode);
int fchmod(int fd, mode_t mode);
```

В качестве параметра chmod указываются те же константы, что и в вызове open.

Вызов возвращает -1 в случае ошибки и 0 – в случае успеха.

Примечание 1: нет отдельного системного вызова для получения флагов доступа к файлу, получить флаги можно вызовом stat().

Примечание 2: маска прав доступа не оказывает влияния на chmod().

Константы доступа

Если указан флаг O_CREAT, то в параметре должны передаваться права доступа к создаваемому файлу. Права задаются комбинацией следующих констант.

Права	Владельца	Группы	Остальных
На чтение	S_IRUSR	S_IRGRP	S_IROTH
На запись	S_IWUSR	S_IRGRP	S_IWOTH
На выполнение	S_IXUSR	S_IXGRP	S_IXOTH
Bce	S_IRWXU	S_IRWXG	S_IRWXO

S_IRWXU | S_IRGRP — какой набор прав?

Блокировка файлов

Блокировка файла – ограничение доступа к файлу или его части.

В POSIX определен единственный тип блокировок – advisory locks (рекомендательные/необязательные блокировки, далее – просто блокировки).

Данные блокировки не позволяют полностью запретить доступ к файлу другим процессам. Но другой процесс может проверить блокировку и узнать, наложена блокировка или нет.

Блокировка снимается автоматически, если файл закрывается.

В некоторых ОС (в т.ч. Linux) вводится еще один тип блокировок — mandatory locks (обязательные блокировки). Данные блокировки полностью запрещают доступ к файлу другим процессам, однако их реализация на уровне ОС имеет ряд недостатков, и потому их использование нежелательно. Подобные блокировки могут налагаться только через fcntl.

Блокировка файлов. Вызов flock (пример 5)

Наложить блокировку на файл можно вызовом flock.

```
int flock(int fd, int operation);
```

B поле operation должна передаваться одна из констант, определяющих тип операции:

- LOCK_SH наложить разделяемую блокировку (блокировку для чтения);
- LOCK_EX наложить исключительную блокировку (блокировку для записи);
- LOCK_UN снять блокировку.

С любой из данных констант можно дополнительного передать флаг LOCK_NB — флаг запрета ожидания.

Примечание: с помощью вызова fcntl можно блокировать не весь файл, а только его часть.

Предотвращение параллельного запуска

Вызов flock() используется для запрета параллельного запуска программ.

Системные программы обычно поступают следующим образом:

- 1. Открывают или создают файл /run/<имя программы>.pid (или по другому фиксированному пути).
- 2. Вызывают flock() с флагами LOCK_EX LOCK_NB .
- 3. Если блокировка наложена успешно записывают в файл текущий идентификатор процесса (см. вызов getpid()) и продолжают выполнение.
- 4. Если блокировка не наложена читают из файла идентификатор блокирующего процесса, выводят сообщение об ошибке и завершаются.

Вызов fcntl

Для получения и изменения некоторых свойств открытого файла используется вызов fcntl.

```
int fcntl(int fd, int cmd, ... /* arg */ );
```

Параметр cmd определяет одновременно и свойство, и действие, которое будет производиться (получение или изменение значения свойства).

Возвращаемое значение также зависит от cmd, но в любом случае при ошибке возвращается -1.

Возможные значения *cmd* перечислены в документации (*man fcntl*). Среди возможностей - наложение блокировок на часть файл, наложение строгих блокировок, управление асинхронным вводом/выводом и т.д.

Файлы устройств

\$ stat /dev/sda

Файлы устройств соответствуют реальным устройствам.

Каждый файл устройства имеет старший и младший номер (см. вывод stat).

Старший номер устройства идентифицирует модуль ядра, который отвечает за работу с устройством.

Младший номер устройства идентифицирует файл устройства.

```
File: /dev/sda
Size: 0 Blocks: 0 IO Block: 4096 block special file
Device: 5h/5d Inode: 152 Links: 1 Device type: 8,0
Access: (0660/brw-rw----) Uid: ( 0/ root) Gid: ( 6/ disk)
Access: 2024-02-11 21:22:57.939572272 +0400
Modify: 2024-02-11 21:22:57.939572272 +0400
Change: 2024-02-11 21:22:57.939572272 +0400
```

Монтирование файловых систем

Файловая система, находящаяся на устройстве, может быть смонтирована в каталог с помощью вызова mount(). Содержимое каталога становится недоступным, но не теряется.

Параметры:

```
source — путь к файлу устройства;
target — путь к целевому каталогу;
filesystemtype — имя монтируемой ФС (fat32/ext4/nfts);
mountflags — флаги монтирования (MS_NOEXEC, MS_RDONLY и др);
data — дополнительные данные, передаваемые модулю ядра.
```

Для размонтирования используется вызов int umount(const char *target);

Файловая система tmpfs

Интересной возможностью является создание файловой системы в оперативной памяти. Работа с файлами в такой файловой системе происходит намного быстрее.

Монтирование в консоли:

```
$ sudo mount -t tmpfs -o size=<paзмep>,mode=777 tmpfs <каталог>
```

Монтирование в программе:

```
mount(NULL, "<каталог>", "tmpfs", 0, "size=<pазмер>, mode=777");
```

Взаимодействие с устройствами (пример 6)

Для взаимодействия с устройством используется вызов ioctl.

```
int ioctl(int fd, unsigned long request, ...);
```

Параметры:

```
fd — дескриптор открытого файла устройства; request — константа, определяющая операцию;
```

Дополнительные параметры, которые принимает вызов, зависят от конкретного устройства и указываются в документации на него.

Отслеживание изменений в файлах (пример 7)

Для отслеживания изменений в каталогах используются системные вызовы набора inotify:

Инициализация отслеживания (пример 7)

```
int fd = inotify_init();
```

Вызов инициализирует очередь событий inotify и возвращает файловый дескриптор, связанный с ней (или -1 в случае ошибки).

Для чтения событий по данному дескриптору используется вызов read().

Отслеживание изменений в файлах (пример 7)

Для отслеживания событий связанных с заданным файлом используется вызов inotify_add_watch().

Параметры:

```
fd – дескриптор очереди событий; pathname – путь, события по которому отслежтиваются mask – маска отслеживаемых событий.
```

Вызов возвращает дескриптор отслеживания, который используется для сопоставления событий. Данный дескриптор нельзя передавать в read().

Для отмены отслеживания используется вызов inotify_rm_watch(int fd, int wd).

Типы событий inotify(пример 7)

Комбинация следующих констант может быть передана в аргументе mask.

```
IN_OPEN – файл/каталог или элемент каталога был открыт
```

- IN_CLOSE файл/каталог или элемент каталога закрыт
- IN_MODIFY файл/каталог или элемент каталога изменен
- IN_ACCESS файл/каталог или элемент каталога был прочитан
- IN ATTRIB свойства файла/каталога или элемента каталога были изменены
- IN_CREATE новый элемент каталога создан
- IN_DELETE элемент каталога удален
- IN_DELETE_SELF отслеживаемый файл/каталог удален
- IN_MOVE_SELF отслеживаемый файл/каталог удален
- IN_MOVED_FROM элемент каталога перемещен из отслеживаемого каталога
- IN_MOVED_TO новый элемент каталога перемещен в каталог

Чтение событий inotify(пример 7)

Для чтения событий отслеживания используется системный вызов read(). Вызов считывает одну или несколько структур inotify event: struct inotify_event { int wd; /* Дескриптор отслеживания */ uint32_t mask; /* Маска, определяющая тип события*/ uint32 t cookie; /* Число для сопоставления событий переименования*/ uint32_t len; /* Размер имени файла в байтах*/ char name[]; /* Имя файла */

Чтение событий inotify(пример 7)

Так как общий размер структуры заранее не известен, буфер для чтения событий следует резервировать с запасом. Достаточно зарезервировать буфер в виде:

```
const char buffer_size = sizeof(inotify_event) + PATH_MAX + 1;
char* buf = calloc(buffer_size);
read(fd, buf, buffer_size);
```

Вызовы read() при успешном завершении считывает целиком как минимум 1 событие. При этом следует учитывать, что в буфер может быть считано более 1 события.

Если размер буфера недостаточен, вызов read() провалится с ошибкой EINVAL.

Если в очереди нет событий, то вызов read() заблокируется до появления события.