Системное программирование

Лекция 3

Процессы

Многозадачность и процессы

Многозадачность – способность ОС управлять выполнением нескольких задач одновременно.

Кооперативная многозадачность – способ реализации многозадачности, при котором моменты передачи управления от одной задачи к другой определяет сама задача.

Вытесняющая многозадачность – способ реализации многозадачности, при котором момент передачи управления от одной задачи к другой определяет среда выполнения.

Процесс – экземпляр выполняющейся программы.

Процесс соответствует программе в целом. Данные программы также являются частью процесса. За исполнение программы отвечают потоки выполнения процесса.

Поток выполнения – системная сущность, представляющая участок программного кода, который может быть выбран планировщиком для выполнения.

У каждого процесса есть как минимум 1 поток выполнения, который в момент запуска начинает выполнять код программы с начала.

Процессы в UNIX

Процессы в UNIX обладают следующими особенностями:

- процесс однозначно определяется **идентификатором процесса** (process id, **PID**) – уникальным в пределах системы целым неотрицательным числом;
- процессы порождаются другими процессами *путем копирования*;
- процессу известен его процесс-родитель;
- у всего «семейного древа» процессов есть корень – **процесс init (PID=1)**;

Процессы в UNIX

Каждый процесс имеет *собственные*:

- адресное пространство, в котором размещаются его данные;
- таблицу дескрипторов;
- набор потоков выполнения;
- ID пользователя и группы, от имени которых он работает;
- маску прав создаваемых файлов (см. *man umask*);
- набор блокировок файлов;
- набор обработчики сигналов и обработчиков `exit()`;
- набор ограничений ресурсов;

и некоторые другие атрибуты.

Идентификаторы процесса (пример 1)

Идентификатор процесса и идентификатор его процесса-родителя можно получить вызовами getpid() и getppid().

```
pid_t getpid();  //получить PID
pid_t getppid(); //получить PID родителя
```

Эти вызовы всегда завершаются без ошибок.

Примечание: в POSIX нет системного вызова, позволяющего вернуть PID дочерних процессов.

Создание процесса. Вызов fork (пример 1)

Процесс создается вызовом fork().

```
pid_t fork();
```

Вызов fork создает **копию*** вызывающего процесса. Выполнение процесса-потомка начинается с выражения после `fork()`.

В процессе-родителе вызов возвращает PID созданного процесса либо -1.

В созданном процессе вызов возвращает 0.

*атрибуты процесса, значения которых не копируются, см. в *man fork*

Создание процесса. Вызов fork

```
int main() {
  int x = 0, *y = new int(101);
  pid_t cpid = fork();
  if(cpid == 0){*y = 102; /*child code*/ }
  else          {/*parent code*/}
}
```

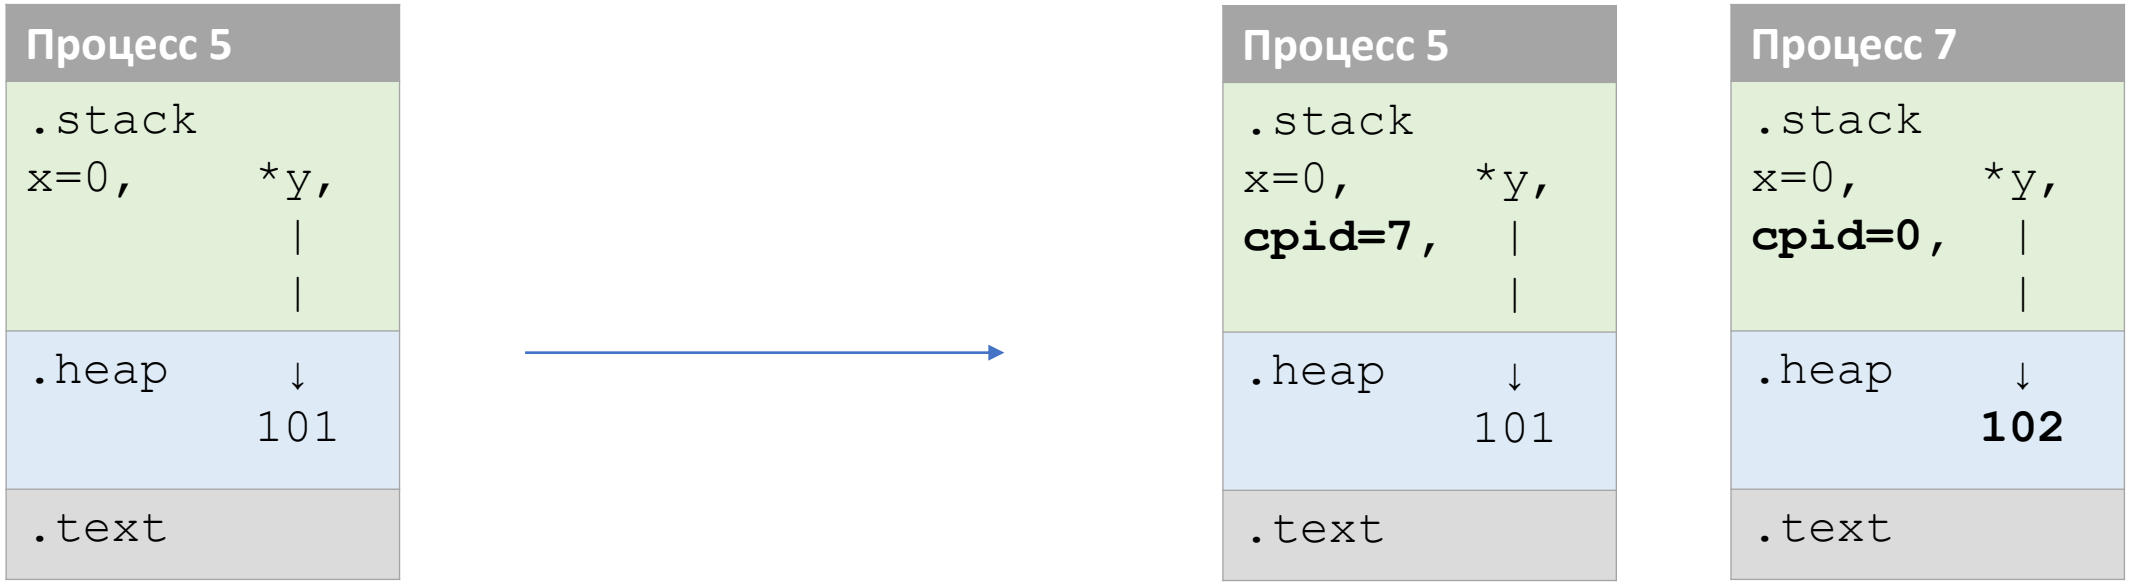

Открытые файлы и fork() (пример 10)

При вызове `fork()` копируется таблица дескрипторов процесса.

Как следствие, в новом процессе будут открыты те же файлы в тех же режимах доступа, что и в исходном процессе на момент `fork()`. *Позиции чтения-записи в открытых файлах также будут общими – вызовы `read/write/lseek()` в одном из процессов будут перемещать позицию для обеих процессов.*

Результат одновременных операций ввода/вывода из разных процессов не определен!

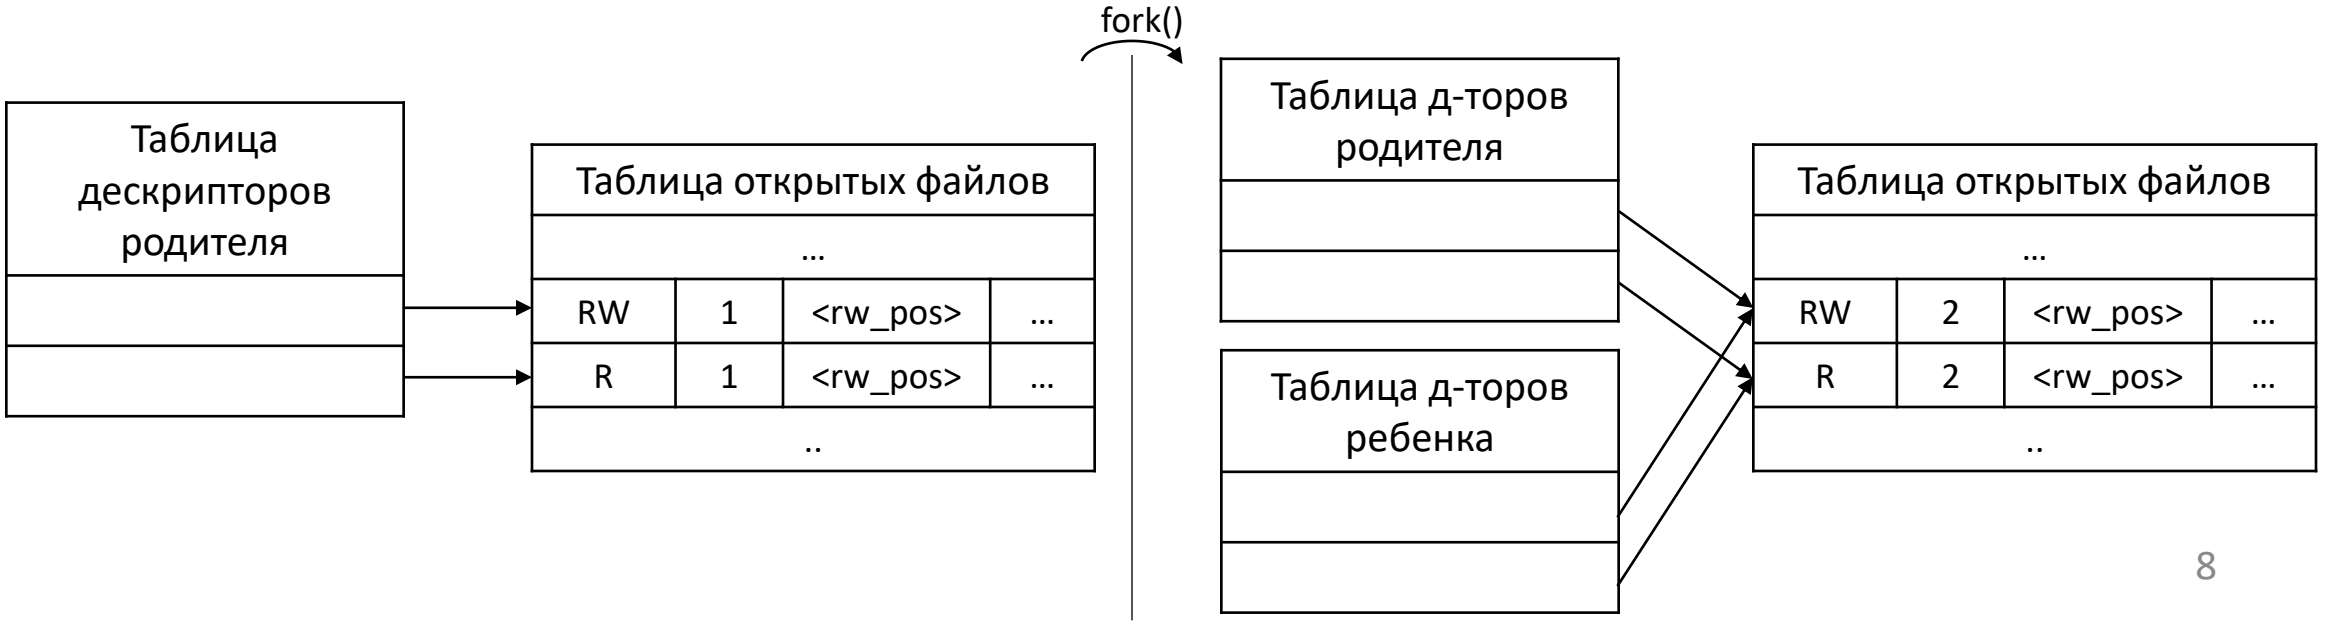

Завершение работы процесса

Процесс завершается *нормально*, если:

- завершено выполнение функции `main()`;
- завершено выполнение всех потоков процесса;
- вызвана функция `exit()` или системный вызов `_exit()`;

При нормальном завершении процесса ОС сохраняет его **код завершения** – результат `main()` или значение, переданное в `exit()`. По общему соглашению, любой код завершения `!=0` означает завершение работы в результате ошибки.

Процесс завершается *не нормально*, если получен сигнал, диспозиция которого – уничтожение процесса (см. след. лекцию).

Завершение процесса(пример 2)

Завершить выполнение процесса можно функцией `exit()`, вызовом `_exit()` или функцией `abort()`.

```
void exit(int status);  /*нормальное завершение*/
void _exit(int status); /*нормальное завершение*/
void abort();           /*аварийное завершение*/
```

Функция exit() позволяет выполнить дополнительные действия при завершении процесса.

Регистрация функции, которая должна выполниться при завершении работы процесса, осуществляется с помощью функции `atexit()` .

```
int atexit(void (*function)(void));
```

Типовым применением `atexit()` является закрытие открытых файлов, вывод финальных сообщений и т.д.

Ожидание завершения дочернего процесса

Часто дочерний процесс создается, чтобы параллельно выполнить некоторое необходимое действие.

Следовательно, нужно дождаться завершения процесса для продолжения работы.

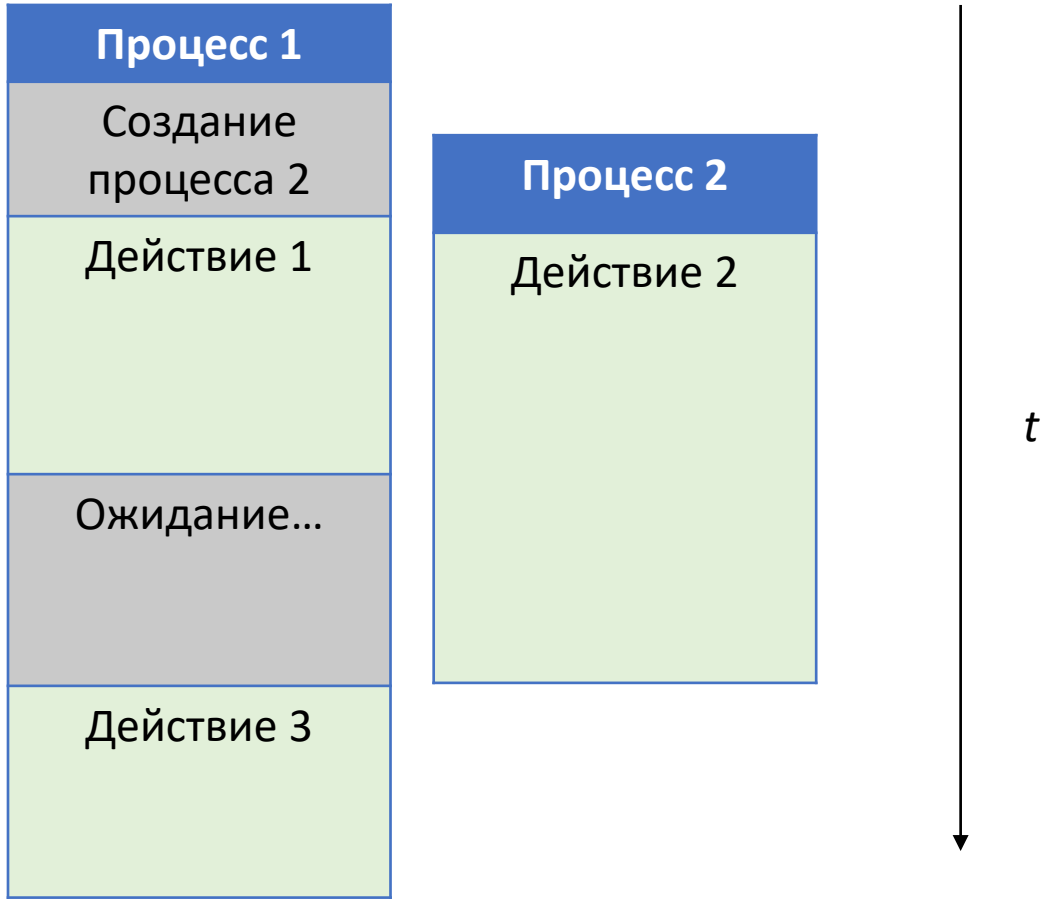

Вызов wait

Подождать завершения работы одного из дочерних процессов можно вызовом `wait()`.

```
pid_t wait(int *wstatus);
```

Вызов приостанавливает текущий поток до тех пор, пока не завершится *любой* из дочерних процессов, после чего возвращает PID завершившегося процесса.

Если параметр **`wstatus`** не равен NULL, по данному указателю записывается информация о завершении процесса.

Вызов waitpid (пример 3)

Вызов `waitpid()` позволяет дождаться изменения состояния конкретного дочернего процесса.

```
pid_t waitpid(pid_t pid, int *wstatus, int options);
```

Параметры:

`pid` – идентификатор ожидаемого процесса (*`man waitpid`*);
`wstatus` – указатель для сохранения информации о завершении процесса;
`options` – дополнительные флаги (`WNOHANG`).

Если в `pid` передать `0`, то вызов будет ожидать любого из дочерних процессов.

Флаг `WNOHANG` позволяет просто проверить, завершился ли данный процесс. Если процесс не завершился, `waitpid()` вернет `0`.

См. также: *`man waitpid`*, флаги `WUNTRACED`, `WCONTINUED`

Параметр wstatus

```
pid_t wait(int *wstatus);
pid_t waitpid(pid_t pid, int *wstatus, int options);
```

Для определения конкретной причины завершения процесса используется ряд макросов (возвращают 1 или 0):

- `WIFEXITED(status)` – процесс завершился нормально;
- `WIFSIGNALED(status)` – процесс «убит» сигналом (нет кода завершения);

Если процесс завершился нормально, код завершения можно получить макросом `WEXITSTATUS(status)`.

Номер сигнала, убившего процесс, можно получить макросом `WTERMSIG(status)`

См. также: *man waitpid*, макросы `WIFSTOPPED(status)`, `WIFCONTINUED(status)`

Таблица процессов. Процессы-зомби

Каждому процессу соответствует запись в системной **таблице процессов**. Данная таблица имеет ограниченный размер.

При завершении работы процесса, запись в таблице не удаляется сразу. В записи продолжает храниться код завершения процесса.

Окончательно запись удаляется из таблицы, когда процесс-родитель забирает код завершения вызовом `wait/waitpid()`.

Процессы, которые завершили выполнение, но о которых еще есть запись в системной таблице процессов, называются **процессами-зомби**.

Слишком большое количество зомби может привести к тому, что системная таблица заполнится, и создавать новые процессы не получится.

См. также: fork-бомба

Процессы-сироты (пример 4)

Если во время работы дочернего процесса завершается его процесс-родитель, дочерний процесс становится **процессом-сиротой**.

Поскольку у каждого процесса должен быть процесс-родитель, процессы-сироты немедленно «усыновляются» одним из процессов-предков*.

Изначально, все процессы-сироты усыновлялись процессом init.

Процесс **init** – первый процесс, запускаемый при старте ОС. **PID init равен 1**.

Процесс init написан так, что всегда забирает код завершения своих дочерних процессов -> init предотвращает появление процессов-зомби.

** Предок должен явно изъявить желание усыновлять потомков,*
см. man 2 prctl (секция PR_SET_CHILD_SUBREAPER)

Адресное пространство

Адресное пространство - уникальный для каждого процесса способ сопоставления данных и их адреса

Адресное пространство процесса разделено на сегменты, каждый из которых имеет собственный набор разрешений на чтение/запись/выполнение (RWX). Соблюдение разрешений контролируется средствами сегментной и страничной адресации.

При запуске программы секции из исполняемого файла копируются в сегменты с соответствующими разрешениями (.text –> сегмент с разрешениями R-X, .rodata – R--, .data/.bss – RW-).

В один сегмент могут быть загружены несколько последовательных секций исполняемого файла, имеющих одинаковый набор разрешений.

Сегмент стека создается при запуске программы и располагается в старших адресах пространства пользователя. Основная куча располагается на границе сегмента данных программы.

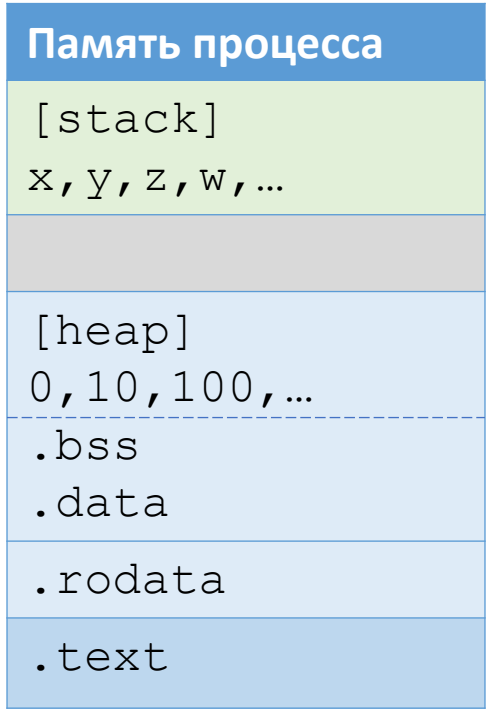

Управление адресным пространством (non-POSIX)

Размер адресного пространства может быть изменен 2 способами.

1. Вызов `mmap()` с флагами `MAP_PRIVATE|MAP_ANONYMOUS` создает новую область памяти, не связанную с файлом. Разрешения на доступ задаются в соответствующем параметре. Удаление области производится с помощью `munmap()`.

2. [non-POSIX] Вызовы `brk()/sbrk()` меняют границу сегмента основной кучи (program break). Разрешения на доступ остаются без изменений. Изменение границы может производится в обе стороны.

Функции `malloc()/free()` и операторы `new/delete` используют оба метода. Для выделения больших объемов памяти используется `mmap()`, для остальных – `brk()`.

См. также: функция mallopt()

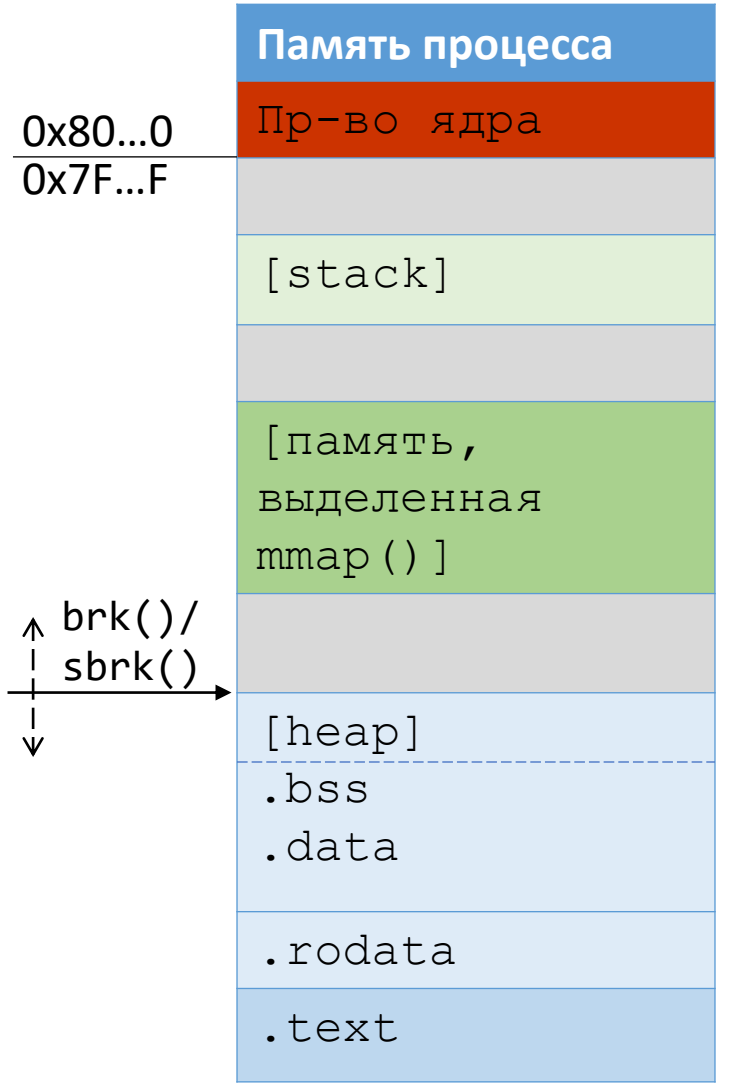

Guard Pages (пример 9)

С помощью вызовов `mmap()` и `mprotect()` можно создавать т.н. **guard pages** – страницы, доступ к которым запрещен (PROT_NONE).

Такие страницы, расположенные до или после защищаемых данных, можно использовать для обнаружения переполнения – попытка переполнения данных приводит к получению сигнала SIGSEGV.

```
void* data = mmap(NULL, 3*PAGE_SIZE, PROT_NONE,
                                     MAP_PRIVATE|MAP_ANONYMOUS, -1, 0 );

mprotect((char*)data+PAGE_SIZE, PAGE_SIZE, PROT_READ|PROT_WRITE);
```

Запуск программ в UNIX

В UNIX новый процесс является копией старого.

Для того, чтобы запустить новую программу, используются системные вызовы семейства `exec*()`. Данные вызовы очищают адресное пространство процесса, загружают в него новую программу и передают выполнение на точку входа.

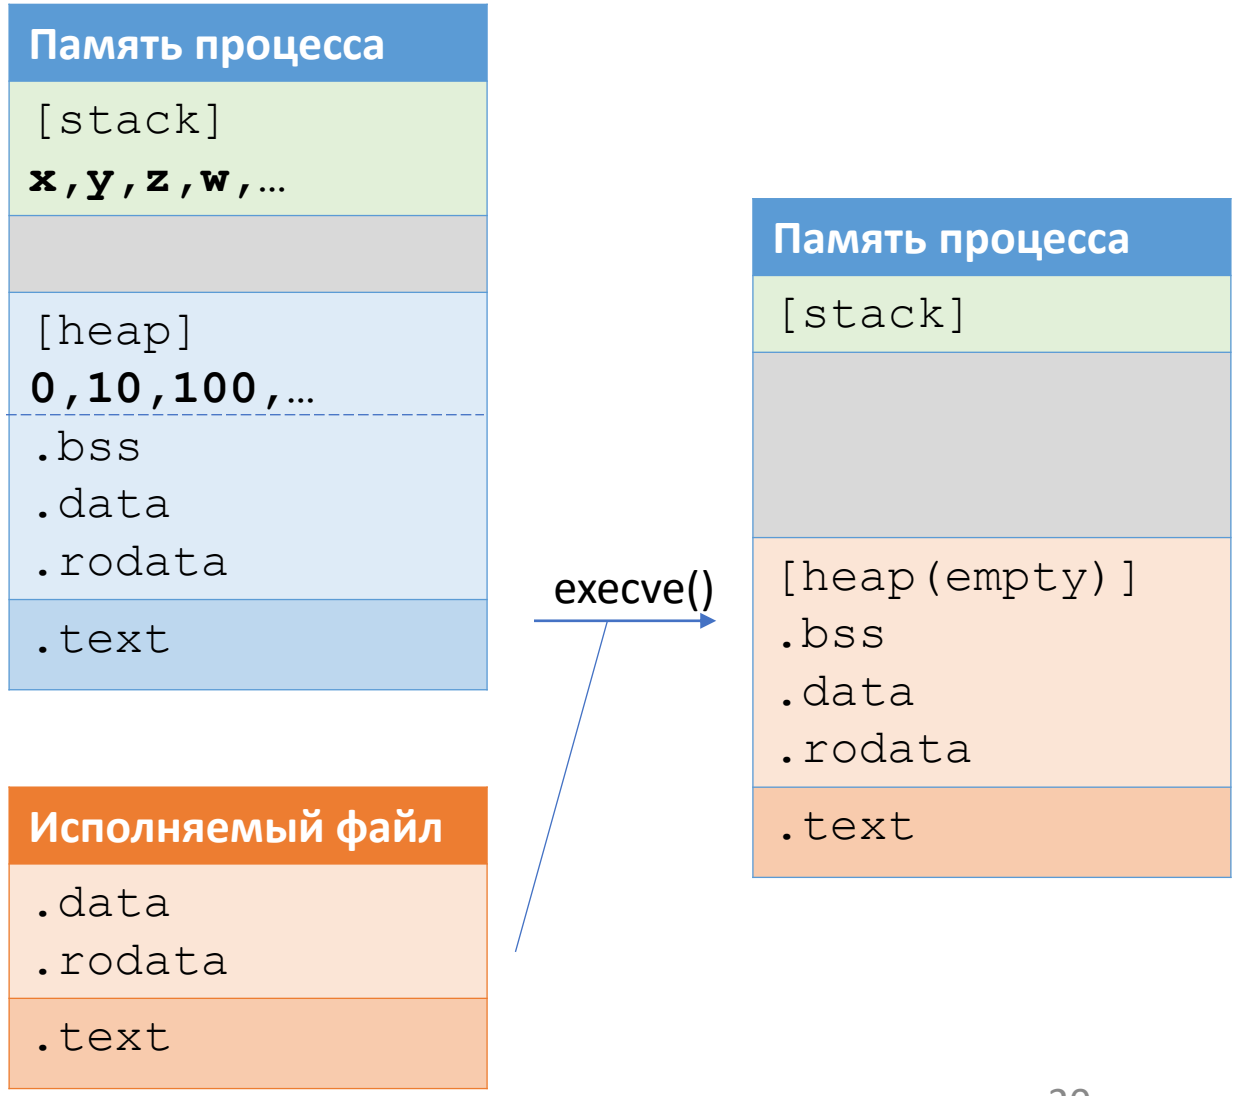

Вызов execve (пример 5)

Для запуска программы из исполняемого файла используется вызов `execve()`.

```
int execve(const char* filename, char* const argv[],
                                 char* const envp[]);
```

Параметры:

`filename` - путь к исполняемому файлу;
`argv` – аргументы программы;
`envp` – переменные окружения (строки вида “*name=value*”).

Последним элементом массивов `argv` и `envp` должен быть `NULL`.

По общему правилу, `argv[0]` представляет команду запуска программы. Проще всего в виде `argv[0]` передавать `filename`.

В качестве `envp` проще всего передать переменную `environ`.

Запуск программ в UNIX

В момент запуска программы:

- Очищается адресное пространство процесса (*без вызова деструкторов объектов для ООП языков!*) – все сегменты создаются заново, старое содержимое полностью теряется.
- Сбрасываются обработчики сигналов и функции, зарегистрированные `atexit()`.
- Закрываются все открытые очереди, семафоры, объекты разделяемой памяти, каталоги.
- Закрываются все дескрипторы с установленным флагом FD_CLOEXEC (*`man 2 fcntl`*).
- Если у исполняемого файла установлен флаг set-user-id/set-group-id, производится установка эффективного User-ID/Group-ID процесса.

Обычные открытые файлы не закрываются. Все маски и ограничения сохраняются.

Скрипты и execve(пример 5)

Скрипт (сценарий) – текстовый файл, описывающий последовательность действий, исполняемую впоследствии интерпретатором скрипта.

Для того, чтобы скрипт можно было выполнять вызовом `execve()`, первая строка скрипта должна иметь вид

`#! <команда запуска интерпретатора скрипта>`

При этом фактически выполняемая команда запуска будет иметь вид

`<команда запуска интерпретатора> <путь к скрипту> <аргументы из execve>`

Примечание: файл скрипта должен иметь разрешение на выполнение

Разделяемые библиотеки

Разделяемые библиотеки – исполняемые файлы специального типа, хранящие функции, используемые другими исполняемыми файлами, и загружаемые в ОЗУ во время работы программы.

Обычно разделяемые библиотеки загружаются автоматически в процессе динамической компоновки. Порядок поиска библиотек в Linux:

1. Каталоги в переменной окружения LD_LIBRARY_PATH;
2. Каталоги в секции DT_RUNPATH исполняемого файла;
3. Системный кэш, формируемый системной утилитой *ldconfig*;
4. Каталоги */lib[64]*, */usr/lib[64]*

Посмотреть список разделяемых библиотек, загружаемых программой, можно утилитой *ldd*.

Ручная загрузка библиотек (пример 6)

Загрузить разделяемую библиотеку вручную можно функцией `dlopen()`.

```
void* dlopen(const char *filename, int flags);
```

Параметры:

`filename` – путь к файлу библиотеки;
`flags` – флаги (**`RTLD_NOW` или `RTLD_LAZY`**, `RTLD_GLOBAL`, и др.).

Вызов возвращает дескриптор библиотеки.

Если в `filename` передать `NULL`, то будет возвращен дескриптор, связанный с таблицей символов всей программы (содержит символы исполняемого файла и всех автоматически загруженных библиотек).

Закрыть дескриптор библиотеки можно вызовом `int dlclose(void *handle);`

Причины ошибок нужно узнавать через `char* dlerror()`, не через `errno`.

Поиск символов (пример 6)

Получить адрес символа по его имени можно функцией `dlsym()`.

```
void* dlsym(void *handle, const char *symbol);
```

Параметры:

`handle` – дескриптор библиотеки;
`symbol` – имя символа.

Функция возвращает указатель на символ или NULL.

Примечание: становиться известен только адрес символа, но не его тип. Неизвестно даже, функция это, или переменная.*

Использование ручной загрузки библиотек применяется при построении расширяемых приложений. Обычно в таком случае пользователь может написать библиотеку с определенными функциями и поместить ее по определенному пути. Программа загрузит библиотеку и будет использовать функции из нее.

** можно узнать через dladdr()*

Процесс как единица управления ресурсами

Процесс является единицей учета ресурсов, т.к. ОС закрепляет ресурсы за процессом. Учитываются:

- размер адресного пространства;
- размер кучи;
- размер стека;
- общее процессорное время;
- количество открытых файлов;
- размер открытого файла (открытый файл не может «вырасти» за этот предел из-за действий текущего процесса);
- и т.д. (см. *man 2 setrlimit*)

Ограничение потребления ресурсов

Для каждого ресурса устанавливаются **мягкий** и **жесткий** пределы потребления.

- при достижении мягкого предела дальнейшее выделение ресурса не производится;
- мягкий предел может быть изменен самой программой, но не может быть выше жесткого предела;
- жесткий предел может быть изменен обычной программой только в сторону уменьшения;
- программы, запущенные от имени суперпользователя, могут менять жесткий предел в сторону увеличения.

Ограничение потребления ресурсов (пример 7)

Для работы с пределами используются вызовы getrlimit/setrlimit().

```
struct rlimit {
    rlim_t rlim_cur;/* мягкий предел или RLIM_INFINITY*/
    rlim_t rlim_max;/* жесткий предел или RLIM_INFINITY*/
};

int getrlimit(int resource, struct rlimit *rlim);
int setrlimit(int resource, const struct rlimit *rlim);
```

Параметры:

resource – константа-тип ресурса (RLIMIT_AS, RLIMIT_NOFILE и др.),
rlim – указатель на значения предела.

Каталог /proc (пример 8)

Каждый процесс в ОС на ядре Linux имеет отображение в файловой системе в виде каталога */proc/<PID>*, где <PID> - идентификатор процесса.

- */proc/<PID>/status* – общие сведения о процессе;
- */proc/<PID>/cwd* – символьная ссылка на рабочий каталог;
- */proc/<PID>/exe* – символьная ссылка на исполняемый файл;
- */proc/<PID>/cmdline* – аргументы программы;
- */proc/<PID>/environ* – переменные среды;
- */proc/<PID>/limits* - пределы;
- */proc/<PID>/maps* – карта адресного пространства;
- */proc/<PID>/mem* – виртуальная память процесса;
- */proc/<PID>/fd* – каталог с файловыми дескрипторами;
- */proc/<PID>/task* – каталог с потоками;

Каталог /proc

- */proc/self* – ссылка на каталог текущего процесса
- */proc/thread-self* – ссылка на каталог текущего потока
- */proc/version* – версия ОС
- */proc/cpuinfo* – информация о ЦП
- */proc/meminfo* – информация об использовании ОЗУ
- */proc/filesystems* – доступные для монтирования файловые системы
- */proc/sys* – каталог с системной информацией
- */proc/sys/kernel* – каталог ядра ОС